Instituto Federal de Educação, Ciência e Tecnologia
do Rio Grande do Norte

Ian de Araújo, Jardson Alan

Impacto das redes sociais na saúde mental de estudantes

Rio Grande do Norte
2026

Ian de Araújo, Jardson Alan

Impacto das redes sociais na saúde mental de estudantes

Artigo apresentado à disciplina de Análise de Dados do Instituto Federal de Educação, Ciência e Tecnologia do Rio Grande do Norte, com o registro do conjunto de dados e do pré-processamento do projeto.

Rio Grande do Norte
2026

Impacto das redes sociais na saúde mental de estudantes

Ian de Araújo[1] e Jardson Alan[1]

RESUMO

Este estudo analisa dados de 4.500 estudantes, do ensino médio à pós-graduação, para investigar se o maior tempo diário de uso de redes sociais está associado a um menor índice de saúde mental. Busca-se medir a intensidade dessa relação e verificar se ela se mantém ao considerar idade, gênero e nível acadêmico. O atributo alvo é o `Mental_Health_Index`. O principal atributo explicativo é o `Daily_Usage_Hours`. O arquivo reúne 16 atributos demográficos, comportamentais e psicométricos, obtidos do conjunto *Impact of Social Media on Life*. Não há valores ausentes no alvo nem nas horas diárias. Há 46 registros ausentes em `Perceived_Stress_Score` e 85 em `Academic_Performance_GPA`. O pré-processamento mantém as 4.500 linhas, seleciona as colunas numéricas e preenche cada vazio de estresse e de GPA com a média truncada de 10% em cada extremidade, calculada entre os estudantes da mesma idade. Em seguida, cada coluna numérica passa a ter média 0 e desvio-padrão 1. A comparação entre idade e índice conserva o desenho da nuvem, e os eixos passam a estar em desvios-padrão.

Palavras-chave: Saúde mental. Redes sociais. Pré-processamento. Média truncada. Padronização.

1 OBJETIVO

Este estudo pretende analisar dados de 4.500 estudantes, do ensino médio à pós-graduação, para investigar se o maior tempo diário de uso de redes sociais está associado a um menor índice de saúde mental. Busca-se medir a intensidade dessa relação e verificar se ela se mantém ao considerar fatores como idade, gênero e nível acadêmico.

O atributo alvo é o `Mental_Health_Index` (índice de saúde mental). Ele será analisado em função do tempo diário de uso de redes sociais (`Daily_Usage_Hours`), que é o principal atributo explicativo. Idade (`Age`), gênero (`Gender`) e nível acadêmico (`Academic_Level`) entram como fatores de controle.

2 CONJUNTO DE DADOS

O arquivo `data/raw/dataset.csv` reúne respostas de 4.500 estudantes, do ensino médio à pós-graduação, sobre tempo de tela, sono, estresse e desempenho acadêmico. São 16 atributos demográficos, comportamentais e psicométricos. A fonte é o conjunto *Impact of Social Media on Life*, publicado por Yadav (2026) no Kaggle sob licença CC0 (domínio público). No Kaggle, o nome do arquivo é `Social_media_impact_on_life.csv`.

[1] Estudantes da disciplina de Análise de Dados do Instituto Federal de Educação, Ciência e Tecnologia do Rio Grande do Norte.

No arquivo local não há valores ausentes em Mental_Health_Index nem em Daily_Usage_Hours. Há ausências em Perceived_Stress_Score (46 registros) e em Academic_Performance_GPA (85 registros).

2.1 ATRIBUTOS

A Tabela 1 apresenta os 16 atributos do arquivo, com o tipo e a descrição de cada um.

Tabela 1 – Atributos do conjunto de dados

Atributo	Tipo	Descrição
Student_ID	Texto	Identificador único do estudante
Age	Inteiro	Idade em anos completos (15 a 26)
Gender	Categórico	Female, Male, Non-Binary ou Prefer not to say
Academic_Level	Categórico	High School, Undergraduate ou Postgraduate
Primary_Platform	Categórico	Instagram, TikTok, YouTube, Snapchat, X (Twitter), Reddit ou LinkedIn
Daily_Usage_Hours	Numérico	Tempo médio diário em redes sociais, em horas. Atributo explicativo principal
Weekend_Extra_Hours	Numérico	Horas extras de tela nos fins de semana
Device_Type	Categórico	Smartphone, Laptop/PC ou Tablet
Sleep_Duration_Hours	Numérico	Duração média do sono por noite, em horas
Sleep_Quality_Score	Inteiro	Qualidade do sono, de 1 (muito ruim) a 5 (excelente)
Late_Night_Usage	Booleano	Uso frequente de tela depois da meia-noite
Social_Comparison_Frequency	Categórico	Never, Rarely, Sometimes, Frequently ou Always
Perceived_Stress_Score	Numérico	Estresse percebido na escala PSS, de 0 a 40
Mental_Health_Index	Inteiro	Índice de bem-estar, de 32 a 98. Atributo alvo
Academic_Performance_GPA	Numérico	GPA acumulado, de 1,9 a 4,0
Overall_Impact	Categórico	Beneficial, Neutral ou Negative

Fonte: Elaborado pelos autores (2026).

3 PRÉ-PROCESSAMENTO

O registro desta etapa é de 23 de outubro de 2026. O fluxo é o main.py, sobre data/raw/dataset.csv.

A leitura fica em src/data/load_data.py e devolve a tabela inteira. As 4.500 linhas permanecem, porque a ausência está em células de duas colunas: 46 registros em Perceived_Stress_Score e 85 em Academic_Performance_GPA. Mental_Health_Index e Daily_Usage_Hours seguem com os valores observados.

A seleção numérica está em src/preprocessing/clean_data.py e mantém as colunas a seguir. Student_ID e os atributos categóricos ou booleanos ficam fora desta etapa. Média e

padronização se aplicam às medidas numéricas. `Age` permanece na tabela e define o grupo do preenchimento.

- `Age` e `Daily_Usage_Hours`.
- `Weekend_Extra_Hours` e `Sleep_Duration_Hours`.
- `Sleep_Quality_Score` e `Perceived_Stress_Score`.
- `Mental_Health_Index` e `Academic_Performance_GPA`.

Cada vazio de estresse e de GPA recebe a média truncada de 10% em cada extremidade, calculada em `src/calculations/descriptive_statistics.py` entre os estudantes da mesma idade. O preenchimento grava esse valor só na célula vazia.

As colunas numéricas estão em escalas diferentes: idade de 15 a 26 anos, horas de uso, de sono e de fim de semana, qualidade do sono de 1 a 5, estresse de 0 a 40, índice de saúde mental de 32 a 98 e GPA de 1,9 a 4,0. `src/preprocessing/standardize_data.py` aplica `StandardScaler`. Cada coluna numérica passa a ter média 0 e desvio-padrão 1.

`src/visualization/charts.py` grava `reports/figures/comparison.png`. A Figura 1 compara `Age` e `Mental_Health_Index` antes e depois da padronização: a nuvem de pontos conserva o desenho, e os eixos passam a estar em desvios-padrão.

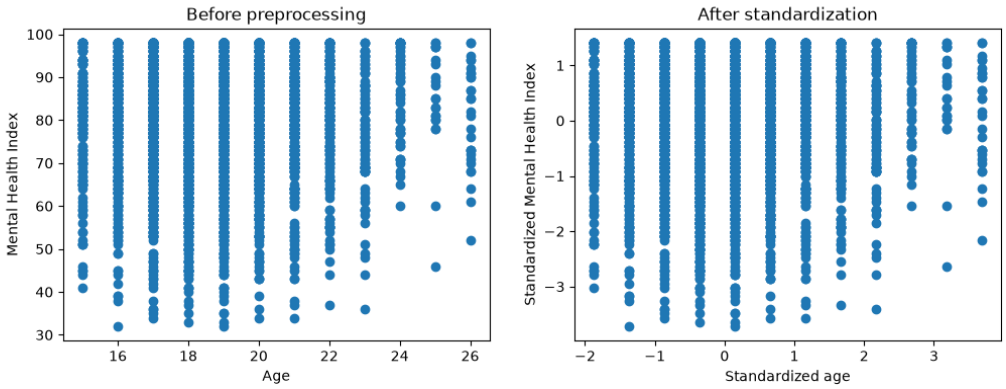


Figura 1 – Idade e índice de saúde mental antes e depois da padronização

Fonte: Elaborado pelos autores (2026).

A ordem executada por `python main.py`, na raiz do projeto, é a seguinte:

1. Carregar `data/raw/dataset.csv`.
2. Selecionar as colunas numéricas.
3. Preencher ausentes com a média truncada por idade.
4. Padronizar com `StandardScaler`.
5. Salvar a comparação de `Age` e `Mental_Health_Index`.

4 CÓDIGO UTILIZADO

As listagens abaixo são os arquivos executados por `python main.py`, na ordem da chamada. O texto é o do repositório, sem alteração.

4.1 FLUXO DE EXECUÇÃO

Arquivo `main.py`.

```python
from src.data.load_data import load_data
from src.preprocessing.clean_data import select_numeric, null_values
from src.preprocessing.standardize_data import standardize_numeric_data
from src.visualization.charts import data_standardization_comparison

def main():
  # Carrega os dados do arquivo CSV
  data = load_data("data/raw/dataset.csv")
  print("Dados carregados com sucesso")

  # Seleciona os dados numéricos
  data_numeric = select_numeric(data)
  print("Dados numéricos selecionados com sucesso")

  # Preenche os valores nulos com a média da coluna (filtrada pela idade)
  data_null = null_values(data_numeric)
  print("Valores nulos preenchidos com sucesso")

  # Padroniza os dados numéricos
  data_scaled = standardize_numeric_data(data_null)
  print("Dados padronizados com sucesso")

  # Compara os dados antes e depois da padronização
  data_standardization_comparison(data, data_scaled)
  print("Comparação dos dados antes e depois da padronização realizada com sucesso
    ")

if __name__ == "__main__":
  main()
```

4.2 LEITURA

Arquivo `src/data/load_data.py`.

```python
import pandas as pd

def load_data(data: str) -> pd.DataFrame:
```

```
4   data_loading = pd.read_csv(data)
5   return data_loading
```

4.3 SELEÇÃO E PREENCHIMENTO

Arquivo src/preprocessing/clean_data.py.

```
1  import pandas as pd
2
3  from src.calculations.descriptive_statistics import (
4    trimmed_mean
5  )
6
7  # Seleciona dados númericos
8  def select_numeric(data: pd.DataFrame):
9    return data.select_dtypes(include="number")
10
11 # Preenchendo valores nulos com a média da coluna (filtrada pela idade)
12 def null_values(data: pd.DataFrame):
13   cols = ["Perceived_Stress_Score", "Academic_Performance_GPA"]
14   data = data.copy()
15   data[cols] = data[cols].fillna(
16     data.groupby("Age")[cols].transform(trimmed_mean)
17   )
18   return data
```

4.4 MÉDIA TRUNCADA

Arquivo src/calculations/descriptive_statistics.py.

```
1  import numpy as np
2
3  # Função para calcular a média truncada (trimmed mean), removendo os valores
       extremos (10% de cada extremidade)
4  def trimmed_mean(values, trim=0.1):
5    sorted = np.sort(values)
6    n = len(sorted)
7    cut = int(np.floor(trim * n))
8    if 2 * cut >= n:
9        raise ValueError("Trim percentage is too large for the dataset size.")
10   return np.mean(sorted[cut : n - cut])
```

4.5 PADRONIZAÇÃO

Arquivo src/preprocessing/standardize_data.py.

```python
import pandas as pd
from sklearn.preprocessing import StandardScaler

scaler = StandardScaler()

# Padronização dos dados numericos
def standardize_numeric_data(data: pd.DataFrame):
  data_scaled = pd.DataFrame(
    scaler.fit_transform(data), columns=data.columns
  )
  return data_scaled
```

4.6 FIGURA DE COMPARAÇÃO

Arquivo src/visualization/charts.py.

```python
import pandas as pd
import matplotlib.pyplot as plt

def data_standardization_comparison(data: pd.DataFrame, data_scaled: pd.DataFrame):

  # Visualização dos dados
  fig, axes = plt.subplots(1, 2, figsize=(12, 4))

  # Gráfico antes da padronização
  axes[0].scatter(data["Age"], data["Mental_Health_Index"])
  axes[0].set_title("Before preprocessing")
  axes[0].set_xlabel("Age")
  axes[0].set_ylabel("Mental Health Index")

  # Gráfico após a padronização
  axes[1].scatter(data_scaled["Age"], data_scaled["Mental_Health_Index"])
  axes[1].set_title("After standardization")
  axes[1].set_xlabel("Standardized age")
  axes[1].set_ylabel("Standardized Mental Health Index")

  # Imagem da comparação antes e após a padronização dos dados
  plt.savefig("./reports/figures/comparison.png")
```

REFERÊNCIAS

[1] YADAV, Harish. **Impact of Social Media on Life**. 2026. Conjunto de dados. Disponível em: https://www.kaggle.com/datasets/harishyadav0506/

impact-of-social-media-on-life. Acesso em: 26 out. 2026.